LABORATORIO 2

Exploración de datos e hipótesis de asociación

Especialización en Analítica Estratégica de Datos - UPTC

Profesor: Duván Cataño | Curso 2026-II | Fecha de análisis: 29 de octubre de 2026

Equipo de TRES estudiantes. Los nombres no fueron suministrados; completar la identificación antes de la entrega.

Datos verificados	Alcance
6,362,620 transacciones	7 variables originales; 4 cuantitativas analizadas, incluidas derivadas
743 horas consecutivas	Objetivo posterior: transacciones por hora
Archivo real disponible	transacciones.csv; huella SHA-256 en manifiesto y JSON
Evidencia reproducible	Notebooks ejecutados, 15 visualizaciones, dashboard y pruebas

Guía de lectura

1. Contexto y calidad. 2. Descriptivas. 3. Forma e IQR. 4. Correlaciones. 5. Contingencias. 6. Comparación de grupos. 7. Síntesis temporal. Anexo: visualizaciones y reproducibilidad.

Los cálculos usan precisión completa. Las medidas se muestran con cuatro decimales y los p-valores menores que 0.0001 se muestran con esa cota. Las pruebas se interpretan como exploratorias bajo sus supuestos, en datos simulados.

1. Contexto, población y calidad

El archivo verificado contiene 6,362,620 transacciones y 7 variables originales. La unidad original es una transacción. La población de referencia son las operaciones del sistema simulado PaySim bajo sus reglas generadoras; el archivo es la muestra disponible, no una muestra probabilística de todos los usuarios bancarios reales. Si se delimita la población al archivo, las descriptivas son censales.

La naturaleza analítica elegida es serie de tiempo. Se construye y(t) = número de filas con step = t para pronosticar el volumen de operaciones por hora. Al agregar cambia la unidad de observación a hora. step es tiempo discreto; monto es la única continua original. Los identificadores numéricos y de cuentas se clasifican como nominales. No hay variable ordinal original ni etiqueta de fraude en estas siete columnas.

Se observaron 0 valores faltantes, 0 identificadores duplicados, 0 montos negativos y 16 montos cero. Las comprobaciones de prefijo de destino dieron 0 inconsistencias. Los ceros se conservan y se dejan señalados para revisar su origen. No se eliminan operaciones solo por ser grandes.

La serie tiene 743 steps entre 1 y 743. Se valida continuidad antes de calcular ACF; una hora ausente no se interpreta automáticamente como cero. La fase step % 24 es reproducible, pero no se conoce una fecha ni un reloj civil. Tampoco se deducen días de la semana reales.

Método: descriptivas, tablas categóricas, Levene, ANOVA y Kruskal usan el archivo completo; Pearson/Spearman/Kendall a nivel transacción usan muestra aleatoria simple sin reemplazo de hasta 200000 filas (semilla 42). Las correlaciones horarias usan todas las horas. Shapiro usa hasta 5000 observaciones por grupo. Nivel de referencia alpha = 0.0500; no se redondea antes de decidir.

Variable original	Tipo
id_transaccion	Nominal (identificador)
step	Cuantitativa discreta
tipo_transaccion	Nominal
monto	Cuantitativa continua
cuenta_origen	Nominal
cuenta_destino	Nominal
tipo_cuenta_destino	Nominal

2. Tendencia central, dispersión y posición

Se analizan step y monto a nivel transacción, y transacciones_hora y monto_promedio a nivel hora. No se copia el conteo de una hora a cada transacción para volver a calcular sus descriptivas: eso ponderaría excesivamente las horas activas. La varianza usa n-1; cuantiles con interpolación lineal; CV = 100 s / |media|. La moda se calcula por valor exacto, se informa multiplicidad si existe empate.

Monto: media 179861.9035, mediana 74871.9400, moda 10000000.0000. La media superior a la mediana indica influencia de la cola derecha. La moda de un monto redondeado puede reflejar reglas o importes repetidos del simulador; no implica que sea un monto típico de la mayoría.

El 50% central de montos se sitúa entre Q1=13389.5700 y Q3=208721.4775. P10=4501.3000 y P90=365423.3090 delimitan el 80% central. El rango es 92445516.6400; la desviación estándar es 603858.2315.

La tabla adjunta contiene las medidas completas. Entre variables de razón comparables, la mayor dispersión relativa es monto. El CV de step se muestra para completar el cálculo, pero su origen temporal es arbitrario y cambia si se traslada el índice, por lo que no es una comparación sustantiva de variabilidad.

En el objetivo horario, media=8563.4186, mediana=529.0000. La diferencia refleja heterogeneidad entre horas activas y horas con actividad baja. No demuestra por sí sola una tendencia temporal.

2. Tablas de medidas

Medida	step	monto	transacciones_hora	monto_promedio
media	243.3972	179861.9035	8563.4186	701708.6334
mediana	239.0000	74871.9400	529.0000	210260.1152
moda	19.0000	10000000.0000	10.0000	No estimable
rango	742.0000	92445516.6400	51350.0000	6185561.5020
varianza muestral	20258.3900	364644763705.5444	179257106.0631	922458462427.4159
desviacion estandar	142.3320	603858.2315	13388.6932	960447.0118
coeficiente variacion porcentaje	58.4772	335.7344	156.3475	136.8726
p10	35.0000	4501.3000	8.0000	117264.1294
q1	156.0000	13389.5700	12.0000	148538.6197
q2	239.0000	74871.9400	529.0000	210260.1152
q3	335.0000	208721.4775	12317.0000	879192.4817
p90	399.0000	365423.3090	31833.0000	1982148.9899

step y monto: 6.362.620 filas. Conteo y monto promedio: 743 horas. El CV del índice step no tiene interpretación invariante al cambio de origen. Conteos n se expresan como enteros. Medidas monetarias sin moneda real atribuida.

3. Forma, gráficos y valores atípicos

Monto tiene asimetría Fisher=30.9939, curtosis Pearson=1800.9567 y exceso=1797.9567. Se clasifica como asimétrica positiva y leptocúrtica. El exceso se obtiene restando 3 a la curtosis Pearson. Una curtosis elevada describe colas y extremos; no equivale simplemente a mayor altura del pico.

Se usa la convención descriptiva |asimetría| <= 0.5 para simetría aproximada y |exceso| <= 0.1 para mesocurtosis aproximada; son umbrales de lectura, no pruebas de normalidad. Histogramas y boxplots se construyen para las variables cuantitativas, y barras para las categorías. Las figuras transaccionales usan hasta 100000 filas (semilla 42); las tablas usan el total.

Con IQR=Q3-Q1=195331.9075, los límites de Tukey son -279608.2913 y 501719.3387. Hay 338,078 montos fuera de ellos (5.3135%). Como sensibilidad, al excluirlos la media pasa de 179861.9035 a 111534.1803 y la desviación de 603858.2315 a 120398.3069. La mediana sin extremos es 63175.8150.

Los atípicos no son automáticamente errores ni fraude. Las horas de mayor actividad pueden ser parte de la estacionalidad. Para modelar monto se propone comparar log1p(monto) y métodos robustos conservando el original. No se garantiza normalidad ni homocedasticidad con una transformación.

Variable	Asimetría	Curtosis	Exceso	Atípicos IQR (%)
step	0.3752	3.3291	0.3291	1.6139
monto	30.9939	1800.9567	1797.9567	5.3135
transacciones_hora	1.3891	3.4629	0.4629	11.7093
monto_promedio	2.4435	9.8431	6.8431	10.0942

4. Covarianza y correlaciones

Como solo hay una continua original, se explicita la adaptación del requisito: pares de continuas derivadas por hora (monto_promedio, monto_mediano) y (monto_total, monto_promedio). Se incluye step-monto como análisis adicional con step discreta. Las tres pruebas contrastan asociación nula de distinto tipo: Pearson lineal, Spearman monotónica por rangos y Kendall concordancia de pares con corrección por empates.

step vs monto (n=200000, Transacciones; step discreta. P nominal bajo independencia.): covarianza=1892173.2297; Pearson=0.0235 (p=<0.0001); Spearman=0.0004 (p=0.8729); Kendall=0.0001 (p=0.9582).

monto_promedio vs monto_mediano (n=743, Horas; continuas derivadas. P nominal por dependencia temporal.): covarianza=575819150580.5616; Pearson=0.8067 (p=<0.0001); Spearman=0.9019 (p=<0.0001); Kendall=0.7339 (p=<0.0001).

monto_total vs monto_promedio (n=743, Horas; continuas derivadas. P nominal por dependencia temporal.): covarianza=-735612500850691.2500; Pearson=-0.2873 (p=<0.0001); Spearman=-0.4944 (p=<0.0001); Kendall=-0.2151 (p=<0.0001).

step vs monto (n=189359, Sensibilidad IQR de la misma muestra.): covarianza=-174078.4140; Pearson=-0.0102 (p=<0.0001); Spearman=-0.0017 (p=0.4548); Kendall=-0.0013 (p=0.4019).

Los diagramas permiten revisar colas, puntos influyentes y curvatura. La sensibilidad IQR vuelve a estimar los tres índices sobre el mismo subconjunto de la muestra, y permite ver cuánto cambia Pearson al reducir extremos. Un coeficiente pequeño puede producir p pequeño con n grande. Spearman y Kendall son más resistentes a magnitudes extremas, pero una relación no monotónica también puede tener correlación por rangos cercana a cero.

La covarianza depende de unidades. monto_total = conteo * monto_promedio, de modo que su asociación con monto_promedio tiene un componente algebraico compartido. Ninguna correlación establece causalidad. Las horas sucesivas y las cuentas repetidas comprometen independencia: los p-valores son nominales exploratorios, no inferencia causal ni garantía de rendimiento fuera de muestra.

5. Independencia categórica e información mutua

Se estudian dos pares: tipo_transaccion vs tipo_cuenta_destino (ambas originales) y tipo_transaccion vs franja_horaria (derivada de step % 24 en bloques 00-05, 06-11, 12-17, 18-23). La franja es una adaptación temporal explícita. Se evita probar millones de identificadores nominales con frecuencias esperadas insuficientes. H0: independencia; H1: dependencia. Chi-cuadrado de Pearson sin corrección de Yates.

tipo_transaccion_vs_tipo_cuenta_destino: chi2=6362620.0000, gl=4, p=<0.0001, MI=0.6398 nats, NMI=0.6570, V de Cramér=1.0000. Mínima esperada=14010.0683, porcentaje de celdas esperadas <5=0.0000%. A alpha=0.0500, se rechaza independencia.

tipo_transaccion_vs_franja_horaria: chi2=49171.8336, gl=12, p=<0.0001, MI=0.0036 nats, NMI=0.0029, V de Cramér=0.0508. Mínima esperada=733.2593, porcentaje de celdas esperadas <5=0.0000%. A alpha=0.0500, se rechaza independencia.

Las tablas observadas y esperadas están en CSV y en los notebooks; esperada(i,j)=total_fila(i)*total_columna(j)/n. MI se obtiene con logaritmo natural y es una magnitud de dependencia, no un p-valor. NMI usa 2 MI/(H(X)+H(Y)); no debe confundirse con MI en nats.

La relación tipo-destino se explica por la regla observada: PAYMENT se dirige a COMERCIO y los otros tipos a CLIENTE. Esto implica redundancia para ciertos modelos; no mide fraude. Para la franja se compara el tamaño de efecto y MI con el p-valor, porque millones de filas permiten detectar efectos pequeños. Las reglas simuladas y la dependencia temporal limitan su generalización.

5. Tablas observadas y esperadas

tipo_transaccion_vs_tipo_cuenta_destino

Observadas

tipo_transaccion	CLIENTE	COMERCIO
CASH_IN	1399284.0000	0.0000
CASH_OUT	2237500.0000	0.0000
DEBIT	41432.0000	0.0000
PAYMENT	0.0000	2151495.0000
TRANSFER	532909.0000	0.0000

Esperadas bajo H0

tipo_transaccion	CLIENTE	COMERCIO
CASH_IN	926121.6031	473162.3969
CASH_OUT	1480898.1501	756601.8499
DEBIT	27421.9317	14010.0683
PAYMENT	1423975.4035	727519.5965
TRANSFER	352707.9116	180201.0884

tipo_transaccion_vs_franja_horaria

Observadas

tipo_transaccion	00-05	06-11	12-17	18-23
CASH_IN	19329.0000	271545.0000	604705.0000	503705.0000
CASH_OUT	18233.0000	416324.0000	992042.0000	810901.0000
DEBIT	3345.0000	6941.0000	15228.0000	15918.0000
PAYMENT	61866.0000	397036.0000	846174.0000	846419.0000
TRANSFER	9832.0000	102716.0000	231635.0000	188726.0000

Esperadas bajo H0

tipo_transaccion	00-05	06-11	12-17	18-23
CASH_IN	24764.3856	262711.1934	591544.3190	520264.1021
CASH_OUT	39599.0469	420083.6251	945898.3406	831918.9874
DEBIT	733.2593	7778.7284	17515.2894	15404.7229
PAYMENT	38076.9391	403936.4555	909539.9108	799941.6946
TRANSFER	9431.3691	100051.9976	225286.1402	198139.4930

6. Variable mixta: monto por tipo de transacción

H0 de Shapiro-Wilk: distribución normal dentro de cada grupo. Se toman hasta 5000 montos aleatorios por grupo porque el p de Shapiro puede ser impreciso por encima de ese tamaño. H0 de Levene centrado en la mediana: varianzas iguales. ANOVA clásica contrasta igualdad de medias; Kruskal-Wallis contrasta igualdad de distribuciones/rangos. Con formas similares puede interpretarse como contraste de localización/medianas, condición que aquí no se da por supuesta.

Shapiro en CASH_IN: n_total=1,399,284, n_test=5000, W=0.9212, p=<0.0001.

Shapiro en CASH_OUT: n_total=2,237,500, n_test=5000, W=0.4636, p=<0.0001.

Shapiro en DEBIT: n_total=41,432, n_test=5000, W=0.3114, p=<0.0001.

Shapiro en PAYMENT: n_total=2,151,495, n_test=5000, W=0.8318, p=<0.0001.

Shapiro en TRANSFER: n_total=532,909, n_test=5000, W=0.2662, p=<0.0001.

Levene-Brown-Forsythe: estadístico=177416.1244, p=<0.0001. ANOVA: F=278715.5421, p=<0.0001, eta2=0.1491. Kruskal-Wallis: H=3906986.6819, p=<0.0001, epsilon2=0.6141.

Como contraste de medias con heterocedasticidad se añade ANOVA de Welch: F=1039325.8302, p=<0.0001. Las pruebas globales significativas indican al menos un grupo diferente, sin identificar por sí solas qué parejas difieren.

En estos resultados se rechazan normalidad por grupo y homogeneidad de varianzas. Se prioriza Kruskal para diferencias distribucionales y Welch para medias. ANOVA clásica se reporta por exigencia de la guía. Kruskal no corrige dependencia entre operaciones ni convierte automáticamente el resultado en una comparación exclusiva de medianas. Para inferencia confirmatoria se necesitarían bloques horarios o agrupación por cuenta, además de post hoc si se requiere localizar diferencias.

Tipo	n	Media	Mediana	Desviación
CASH_IN	1399284	168920.2420	143427.7100	126508.2553
CASH_OUT	2237500	176273.9643	147072.1850	175329.7445
DEBIT	41432	5483.6653	3048.9900	13318.5355
PAYMENT	2151495	13057.6047	9482.1900	12556.4502
TRANSFER	532909	910647.0096	486308.3900	1879573.5289

7. Síntesis y conexión con SARIMA

Para el objetivo transacciones_hora, el historial y la fase diaria son candidatos directos. ACF(1)=0.9235 y ACF(24)=0.7546. La fase 19 tiene el mayor promedio (20897.2258 transacciones); la fase menos activa promedia 40.0323. El desfase entre step y reloj civil no está documentado.

Asociación del objetivo con rezago_1: Pearson=0.9239, Spearman=0.6842, Kendall=0.5221, n=742. Estos indicadores exploran utilidad de rezagos y no equivalen a importancia predictiva validada.

Asociación del objetivo con rezago_24: Pearson=0.8046, Spearman=0.6071, Kendall=0.4685, n=719. Estos indicadores exploran utilidad de rezagos y no equivalen a importancia predictiva validada.

Ljung-Box en 24 rezagos sobre la serie original: estadístico=3775.3124, p=<0.0001. Detecta autocorrelación conjunta, no demuestra por sí solo estacionalidad. ADF en log1p(conteo): estadístico=-2.3727, p=0.1496. H0 de ADF es raíz unitaria. En este archivo no se rechaza al 5%, por lo que no se asume estacionariedad del nivel. Su decisión no descarta cambios de régimen ni sustituye el diagnóstico estacional.

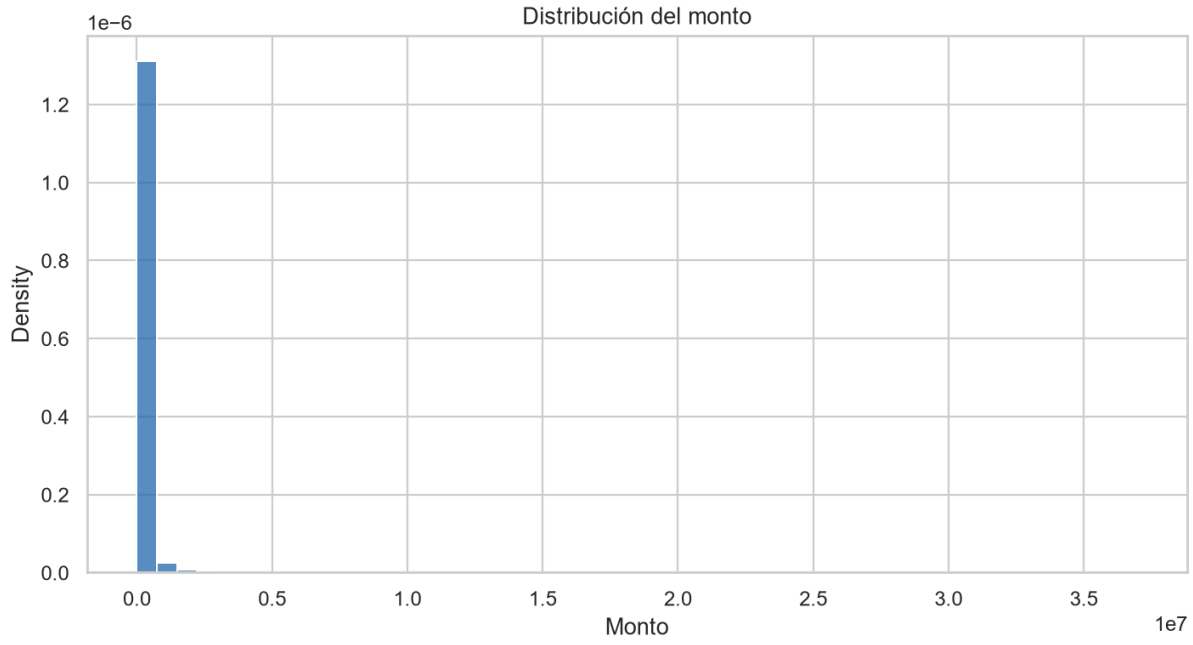
Se recomienda estudiar SARIMA(p,d,q)(P,D,Q,24), compararlo con un pronóstico ingenuo estacional y evaluar ventanas de validación cronológica. Las órdenes d y D se deciden después de inspeccionar diferenciación, ACF/PACF y estacionariedad; no se eligen solo por ADF. Reservar un bloque final y medir MAE/RMSE; revisar residuos y predicciones no negativas. Este laboratorio es EDA, no presenta un SARIMA entrenado ni resultados de pronóstico inventados.

Descartar identificadores de transacción y cuentas como predictores numéricos. Conservarlos para trazabilidad. Evaluar redundancia de tipo_cuenta_destino con tipo_transaccion. Para monto, considerar log1p y estadísticas robustas; para conteo, evaluar si log1p mejora residuos. La composición por tipo o monto de la misma hora solo se conoce al cerrar esa hora: no debe entrar como predictor contemporáneo del conteo futuro. Si se usa, rezagarlo y pasar a un modelo con exógenas (SARIMAX) validando disponibilidad.

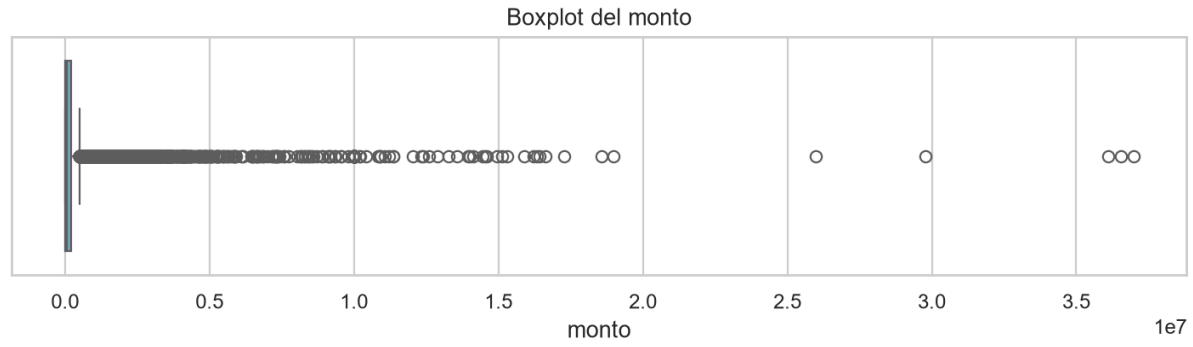
Conclusión del grupo: el volumen horario se relaciona descriptivamente con su historial y la fase temporal. La asimetría y los extremos obligan a interpretar medias y correlaciones junto con medianas, rangos y tamaños de efecto. La evidencia es propia del simulador y del periodo observado; no atribuye causas reales como promociones, demanda de clientes o fraude que no se midieron.

Anexo A. Visualizaciones

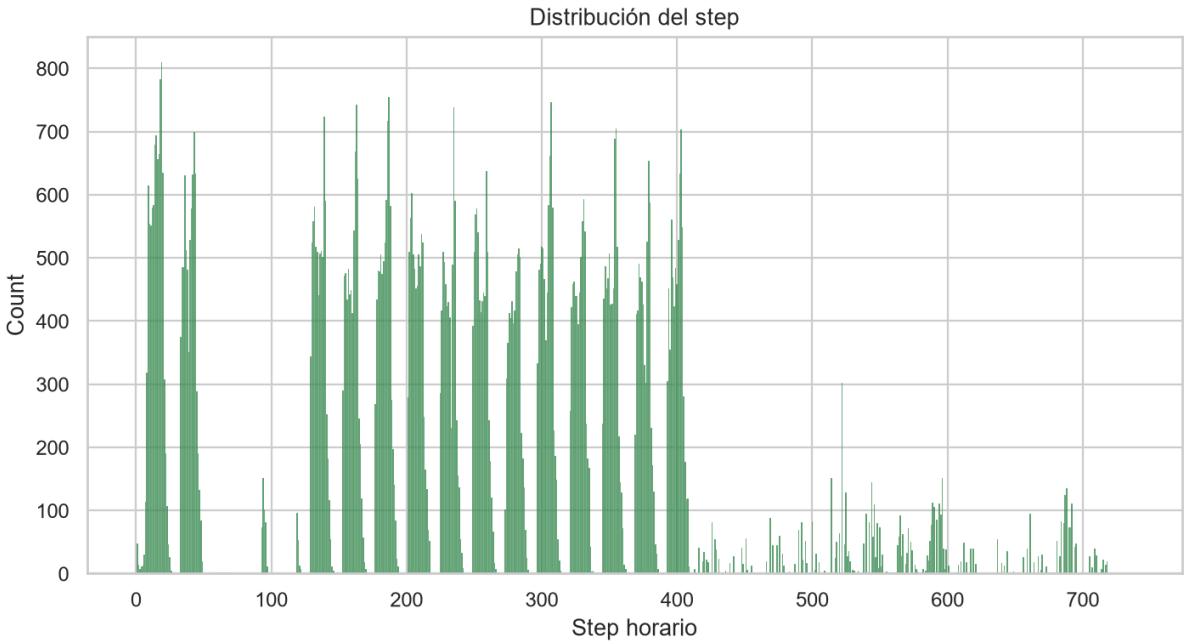
Las figuras transaccionales usan una muestra fija de hasta 100000 filas para legibilidad. Las figuras horarias usan la serie completa. Los boxplots marcan extremos estadísticos, no fraude. En el gráfico por tipo se omiten puntos extremos por legibilidad y se informa una escala transformada.



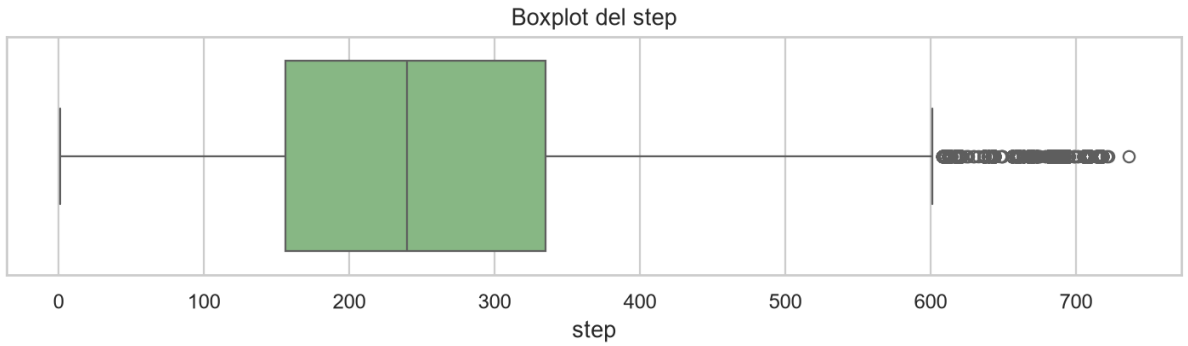
histograma monto



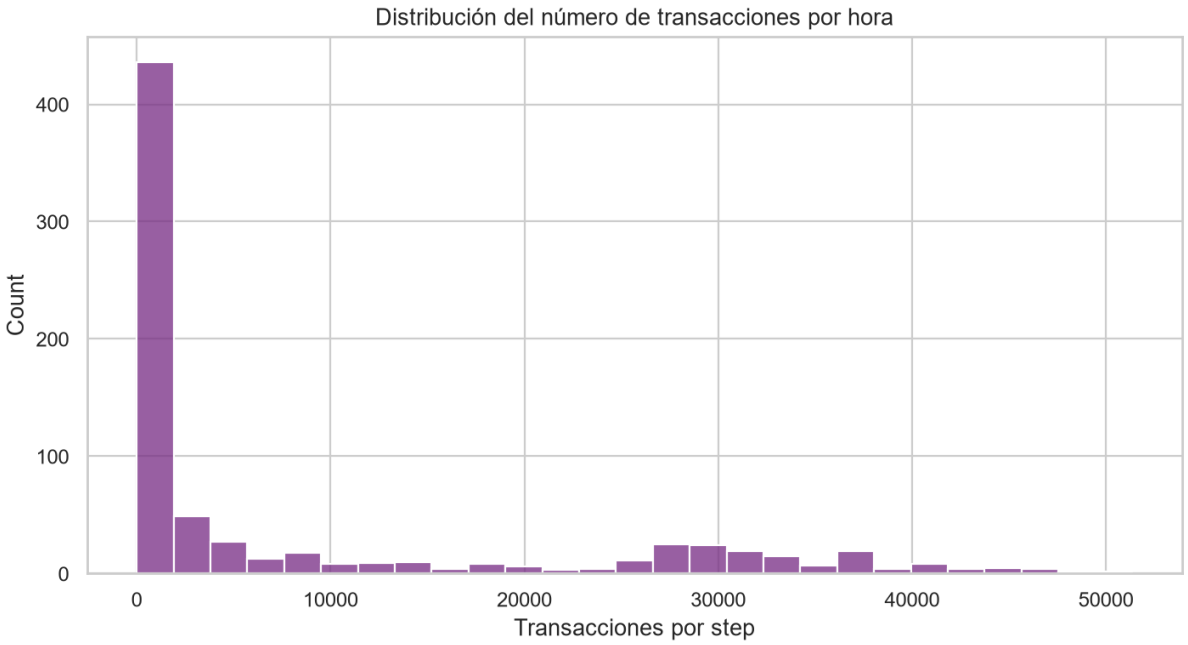
boxplot monto



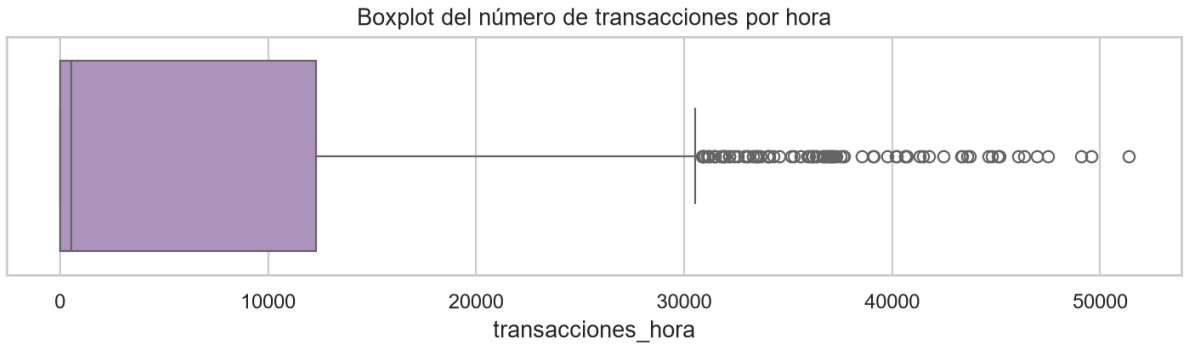
histograma step



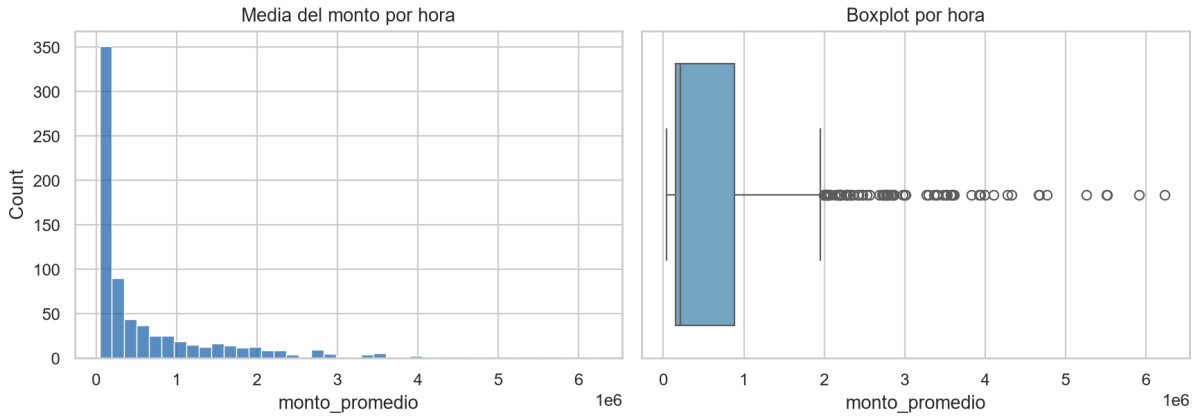
boxplot step



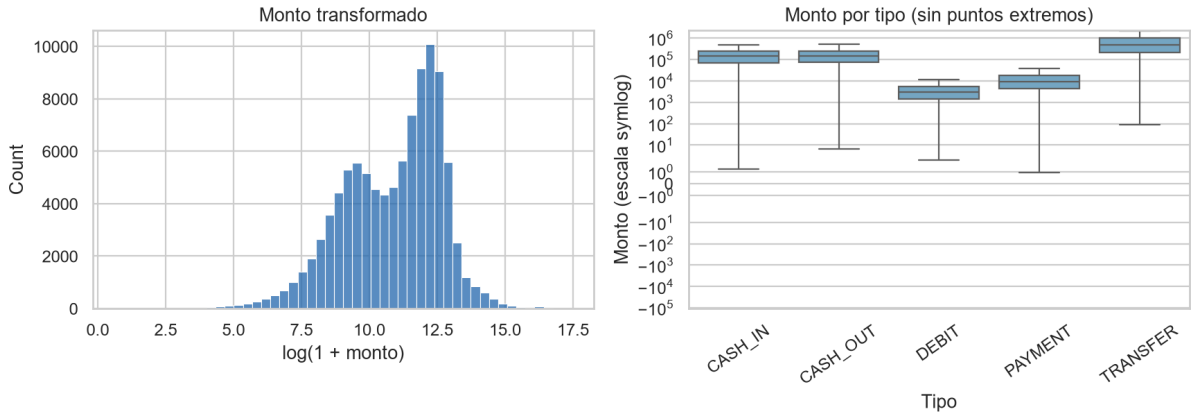
histograma transacciones hora



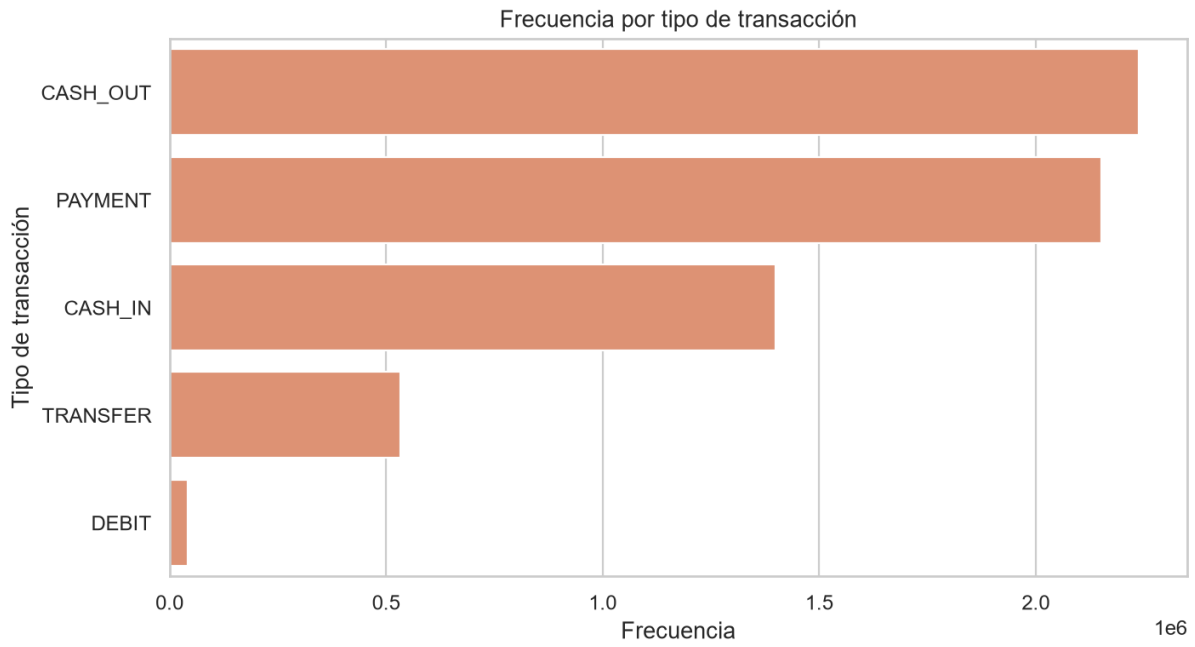
boxplot transacciones hora



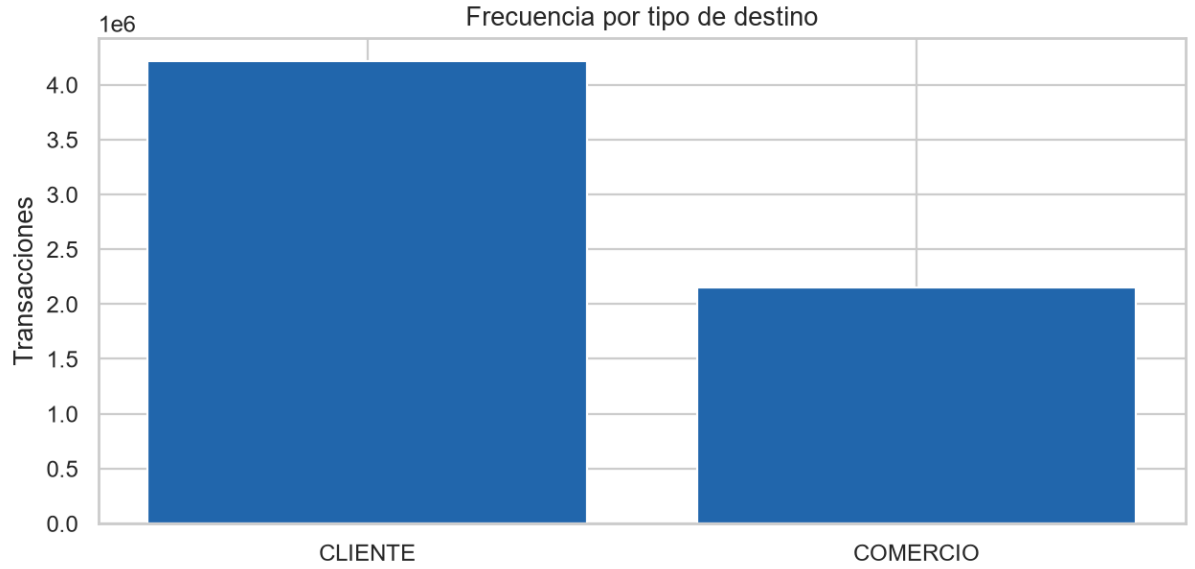
distribucion monto promedio



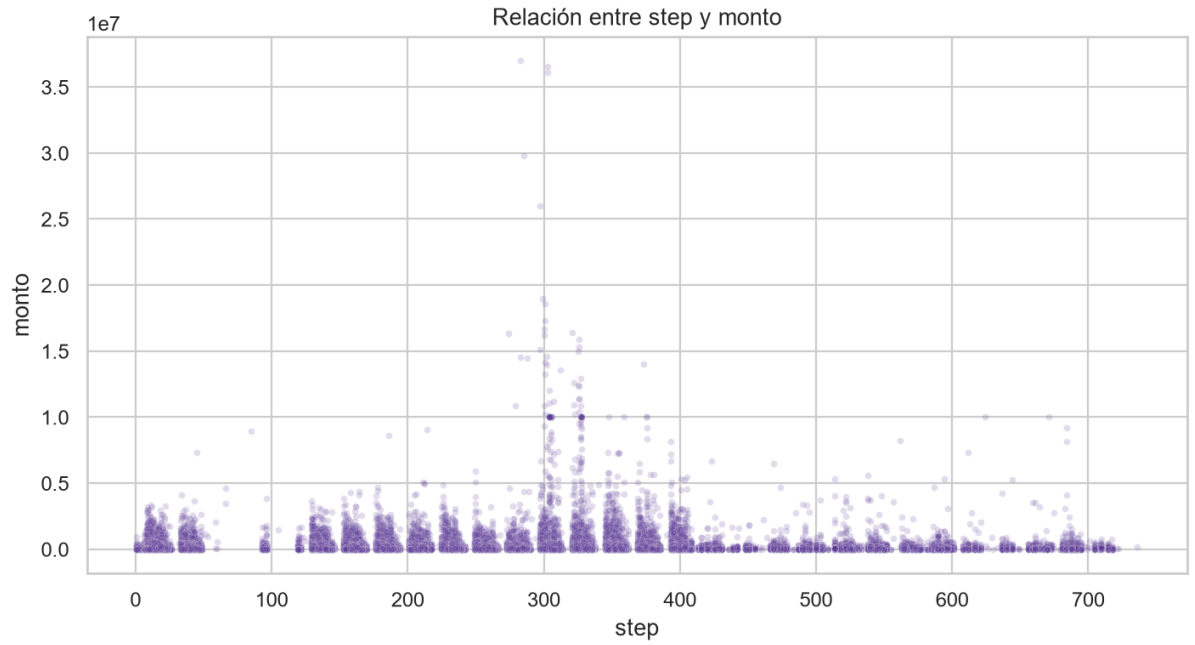
monto transformado grupos



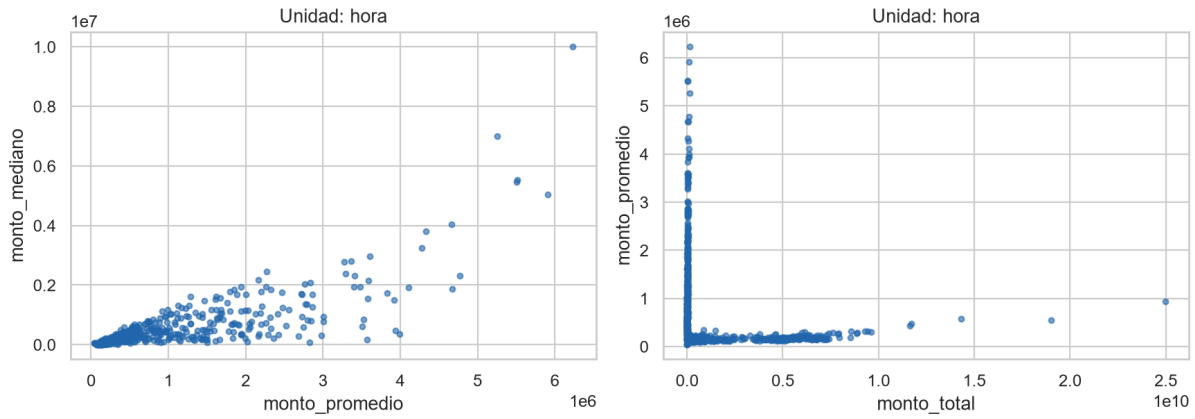
barras tipo transaccion



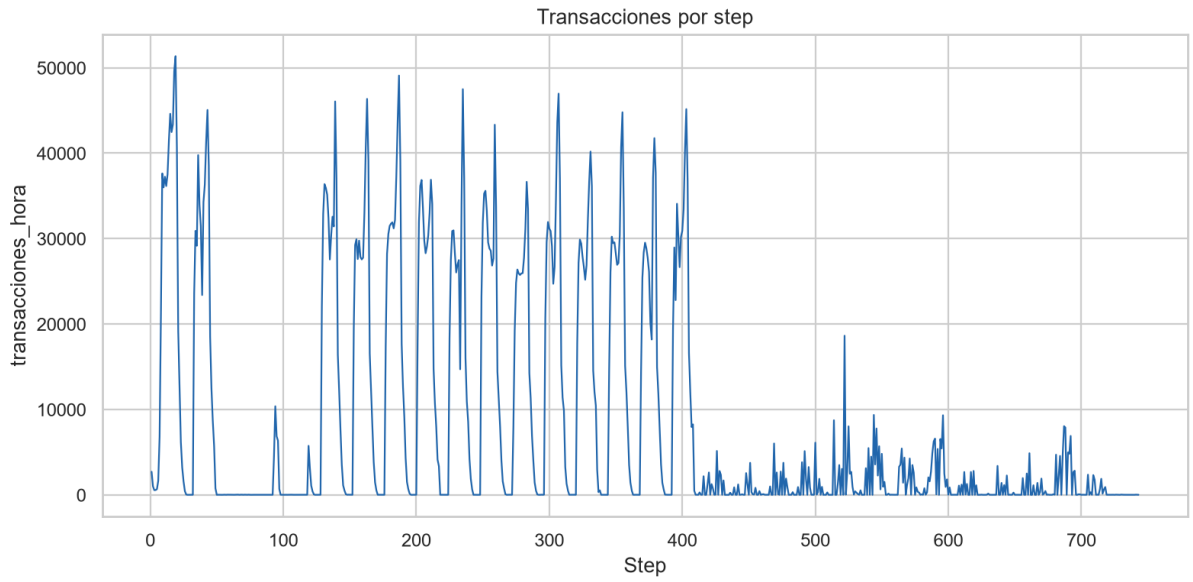
barras tipo destino



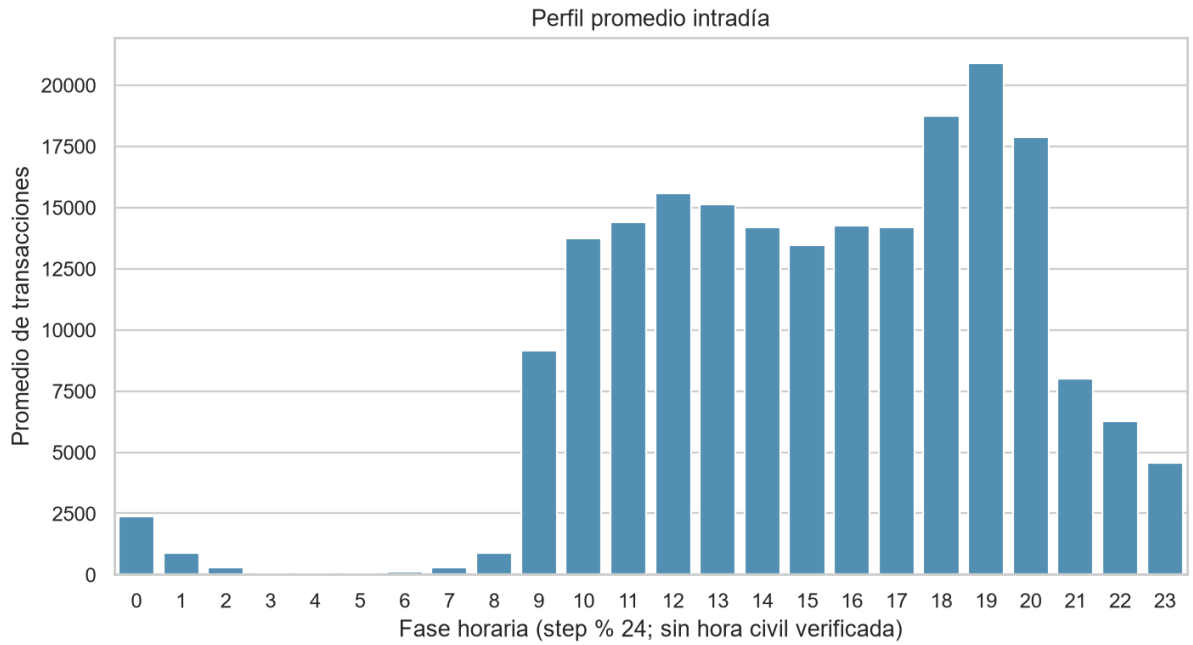
scatter step monto



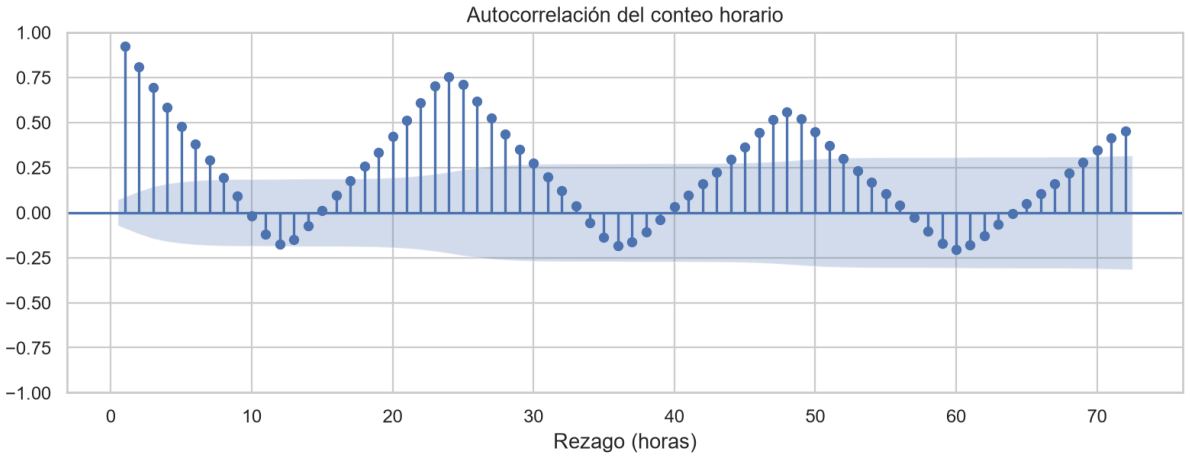
scatter montos horarios



serie transacciones hora



perfil intradia


Autocorrelación del conteo horario
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
0
10
20
30
40
50
60
70
Rezago (horas)

acf conteo

Anexo B. Reproducibilidad y fuentes

Ejecutar desde la raíz del proyecto: pip install -r requirements.txt; python scripts/run_analysis.py --data data/transacciones.csv; python scripts/create_report.py; streamlit run app.py. Los comandos se detallan para Windows en README. El CSV completo no se incorpora al ZIP por tamaño, pero las rutas, el esquema y su huella permiten verificar el mismo archivo.

SHA-256: 262ae36b53af5b4a7798a1429d389710ff6926f2e81f2d6842e1b3626765f684

Python: 3.14.7 | Versiones científicas: {'pandas': '3.1.0', 'numpy': '2.5.4', 'scipy': '1.18.1', 'statsmodels': '0.15.0', 'scikit-learn': '1.9.1', 'matplotlib': '3.11.2', 'streamlit': '1.66.1'}

Duván Cataño. Laboratorio_2.pdf, pp. 1-2: requisitos de los siete apartados y entregable.

Duván Cataño. Presentación del curso (2026-II), pp. 10-15: EDA, asociación y series de tiempo.

Notebooks de referencia: Visualizacion_Frecuencias, Estadistica_Descriptiva, Exploration_Data_Regr y Exploration_Data_Class. Se adaptan a este esquema; sus datasets y conclusiones no se transfieren.

SciPy. Shapiro-Wilk: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html (consulta 2026-10-29).

SciPy. Kruskal-Wallis: https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.kruskal.html (consulta 2026-10-29).

PaySim, repositorio del autor: https://github.com/EdgarLopezPhD/PaySim (consulta 2026-10-29). Respalda el carácter simulado; el esquema adaptado se verifica en el CSV local.

Distribución sugerida entre tres integrantes: 1) contextualización, calidad y descriptivas; 2) correlaciones, contingencias y pruebas mixtas; 3) síntesis temporal, aplicación y revisión de reproducibilidad. Los tres revisan las conclusiones y la sustentación.